Семичев Сергей

①

слой	вход	выход	параметры
conv1 7×7 s2	3×S	32×S/2	3·32·49 = 4.704
maxpool 3×3 s2 p1	32×S/2	32×S/4	0
conv2 5×5	32×S/4	64×S/4	32·64·25 = 51.200
conv3 3×3 s2	64×S/4	128×S/8	64·128·9 = 73.728
conv4 1×1	128×S/8	256×S/8	128·256 = 32.768
conv5 3×3 s2	256×S/8	256×S/16	256·256·9 = 589.824
conv6 1×1	256×S/16	512×S/16	256·512 = 131.072
GAP → fc1 → ReLU → fc2	512	100	131.072 + 25.700

Итого: 883.296 + 131.328 + 25.700 = 1.040.324
Весь: 4 × 1040324 = 4.161.296 ≈ 4.2 Мб

② FLOPS'ы

$MAC_{conv} = C_{in} \cdot C_{out} \cdot k^2 \cdot H_o W_o$

$MAC_{fc} = n_{in} \cdot n_{out}$

слой	$C_{in}C_{out}k^2$	H_oW_o	MAC/pic
conv 1	4.704	$S^2/4$	$1.176 \cdot S^2$
conv 2	51.200	$S^2/16$	$3.200 \cdot S^2$
conv 3	73.728	$S^2/64$	$1.152 \cdot S^2$
conv 4	32.768	$S^2/64$	$512 \cdot S^2$
conv 5	589.824	$S^2/256$	$2.304 \cdot S^2$
conv 6	131.072	$S^2/256$	$512 \cdot S^2$
fc1 + fc2	–	–	131.072 + 25.600

$8.856S^2 + 156.672$

www.brauberg.com

$\Rightarrow$ FLOPs$_{ss}(S,B) = B(17.712S^2 + 313.344)$

e.g.: $S=224, B=1$: $17.712 \cdot 50.176 + 313.344 \approx 0.89$ GF..

③ пиковая память

байты на пиксель S^2/pic в момент:

		Б/S^2
conv 1	$\times 12 \to$ out $85^2 \cdot 4 = 32$	44
~~BORN 2~~ maxpool	$\times 12 \to$ in 32 $\to$ out $2S^2 \cdot 4 =$ $= 8 \to$ idx $2S^2 \cdot 8 = 16$	68
conv 2	$12 \to 8 \to 16$	36
conv 3	$12 \to 16 \to 8$	36
conv 4	$12 \to 8 \to 16$	36
	$12 \to 16 \to 4$	32
....	$12 \to 4 \to 9$	24

$\Rightarrow$ MEM$(S,B) = 4.161.296 + 68BS^2$ Байт

e.g.: $S=512, B=256 \Rightarrow 68 \cdot 262.144 \cdot 256 \approx 4.5$ ГБ

OOM boundary: $BS^2 > (M_{GPU} - W)/68$

$\Rightarrow$ на T4(~15ГБ) при $S=512$ это $B \geq 870$

④. latency

3 границы времени:

1) launch bound. t_{op} 2) mem. bound. Q_k/BW

3) compute bound. $F_{k/P}$ - упор в флопсы

$t_k = \left(t_{op}, \frac{F_k(S,B)}{P}, \frac{Q_k(S,B)}{BW}\right) \max$ | $lat(S,B,\Theta) = \sum_{k=1}^{17} t_k$

$\Theta = (t_{op}, P, BW)$ | $F_k = B(d_k \cdot S^2 + c_k)$ и $Q_k = B(q_k S^2 + d_k) + W_k$

BRAUBERG

www.brauberg.com

ex 1. S=224, B=1 (launch bound)

=> из 17 кернелов только 2 > t_{op}:

conv2: $F = 3.2 \cdot 10^8$, $F/P = \frac{3.2 \cdot 10^8}{4.6 \cdot 10^{12}} = 70.3$ мкс
conv5: $F = 2.3 \cdot 10^8$; ... $= 50.7$ мкс

ост. 15 упираются в запуск: $15 \cdot 32 \approx 482$ мкс

$T = 482 + 70 + 50 = 0.6$ мс, замер 0.5 мс => ~ укладываемся

ex.2 S=224, B=32

кернел	F/P мкс	Q/BW, мкс	t_k, мкс	Режим
conv1	828	648	827	C
relu	0	942	942	M
maxpool	0	824	825	M
conv2	2255	355	2254	C
relu2	0	471	471	M
conv3	812	356	811	C
relu3	0	235	235	M
conv4	361	354	361	C
relu4	0	471	471	M
conv5	1623	316	1623	C
relu5	0	118	118	M
conv6	361	181	361	C
relu6	0	235	235	M
avg.pool	0	118	118	M
fc1,relu,fc2	<2	<6	3×32	L

T=9.75 мс | замер 8.171мс => ошибка ~18%

~~При переходе launch => compute~~

ИТОГО: MAPE на проверке 13.7%, медиана 9%

(5.) Энергия

1. $E = P_S \cdot T + e_{flop} \cdot F + e_{byte} \cdot Q$. $P = 54.1$ Вт, $e_{flop} = 4$ нДж/FLOP

а) S=224, B=1: $54.1 \cdot 0.6 \cdot 10^{-3} + 4 \cdot 10^{-12} \cdot 8.9 \cdot 10^8 = 0.03 + 0.003 = 0.036$
при замере 0.0321 Дж

б) S=224, B=32: $54 \cdot 9.7 \cdot 10^{-3} + 4 \cdot 10^{-12} \cdot 2.9 \cdot 10^{10} = 0.528 + 0.116 = 0.664$ Дж
при замере 0.56 Дж, на картинку 17 мДж vs 32 мДж при B=1

Итог

① t_{op} = 32.2 мкс

P = 4.56 FLOPs

BW = 109 Гб/с

P_{static} = 54 Вт

e_{flop} = 4.1 пДж/FLOP

e_{byte} = 0

②

	MAPE fit	MAPE val
FLOPs	0	0
Latency	13%	13.7%
memory	18.8%	17.3%
energy	14.5%	13.6%

BRAUBERG