Exclusive Self-Attention: эксперимент на GPT-45M

Воспроизведение результатов статьи на FineWeb · Efficient Models, домашнее задание № 2 · октябрь 2026

В статье **Exclusive Self Attention** предлагается небольшое изменение в self-attention: из результата внимания вычитается компонента, направленная вдоль value-вектора самого токена. Идея в том, что attention не должен тратить часть своей работы на возвращение информации, которая уже проходит через residual connection. Авторы показывают выигрыш на больших языковых моделях. Мы решили проверить, сохранится ли он на гораздо меньшем GPT, который можно обучить на одной машине.

Для сравнения обучались две модели с одинаковой архитектурой и начальными весами. Единственное различие между ними — операция XSA после обычного causal attention. Всего проведено **12 обучений**, то есть шесть пар SA/XSA с совпадающими условиями внутри каждой пары.

Что меняет XSA

Пусть y — результат attention для токена в отдельной голове, а v — value-вектор этого же токена. В обычном Self-Attention выход y передаётся дальше без изменений. В XSA он заменяется на z:

$$\hat{v}_{t,h} = v_{t,h} / \max(\|v_{t,h}\|_2, \varepsilon)$$
$$z_{t,h} = y_{t,h} - (y_{t,h}{}^{\mathrm{T}} \hat{v}_{t,h})\, \hat{v}_{t,h}$$

Проекция вычитается **по каждой голове до выходного линейного слоя**. Softmax и causal mask остаются прежними, RoPE применяется к Q и K. Обучаемых параметров XSA не добавляет. Векторы z и v после этой операции почти ортогональны; ниже мы используем это как проверку реализации, а не как показатель качества.

Как проводилось сравнение

Мы использовали GPT в стиле NanoGPT: 6 Transformer-блоков, размер скрытого представления 512, 8 голов attention и RoPE. В обеих версиях **44,65 млн параметров**, предобученные веса не использовались. Данные — тексты из **FineWeb**, токенизация GPT-2 BPE. Обучающая и валидационная части разделялись на уровне документов.

Обучение проводилось с AdamW (максимальный learning rate 6×10^{-4}, 100 шагов warmup, затем cosine decay). Размер глобального батча — 4096 токенов для 10M и 65536 для остальных серий; оценка качества — по всей отложенной части корпуса. Основная метрика — средняя отрицательная логарифмическая правдоподобность токена (**NLL**). Для более привычной интерпретации приводится perplexity: **PPL = exp(NLL)**. У обеих метрик меньше — лучше.

Обучение на пару	Контекст	Seed	Для чего запускалось
10 млн токенов	256	42, 43, 44	Проверка устойчивости разницы
30 млн токенов	256 и 512	42	Проверка на двух длинах контекста
100 млн токенов	1024	42	Отдельная более длинная серия

Здесь 10/30/100 млн — число обработанных при обучении токенов, а не уникальных токенов в корпусе. Внутри каждой пары совпадали seed, начальные веса, порядок обучающих окон, оптимизатор и бюджет. **Между сериями** менялись не только число обработанных токенов и контекст, но и объём подготовленного корпуса и размер батча; поэтому напрямую сравнивать величину эффекта между ними нельзя.

Основная серия: 10 млн токенов, три seed

Seed	NLL SA	NLL XSA	Разница NLL	PPL SA	PPL XSA
42	5,6511	5,6148	0,0363	284,60	274,47
43	5,6532	5,6187	0,0345	285,20	275,52
44	5,6635	5,6157	0,0479	288,17	274,70
Среднее	**5,6559**	**5,6164**	**0,0396**	**285,99**	**274,90**

Во всех трёх запусках XSA закончила обучение с меньшей ошибкой. Средняя **парная разница NLL составила 0,03956**, стандартное отклонение по трём seed — **0,00725**. Средняя perplexity уменьшилась с **285,99** до **274,90**, то есть примерно на **3,9%**.

На графике показана не абсолютная ошибка, а разница между моделями на одних и тех же промежуточных контрольных данных. Значения выше нуля означают преимущество XSA. Разница остаётся положительной почти на всём показанном участке обучения, а не возникает только на последнем шаге.

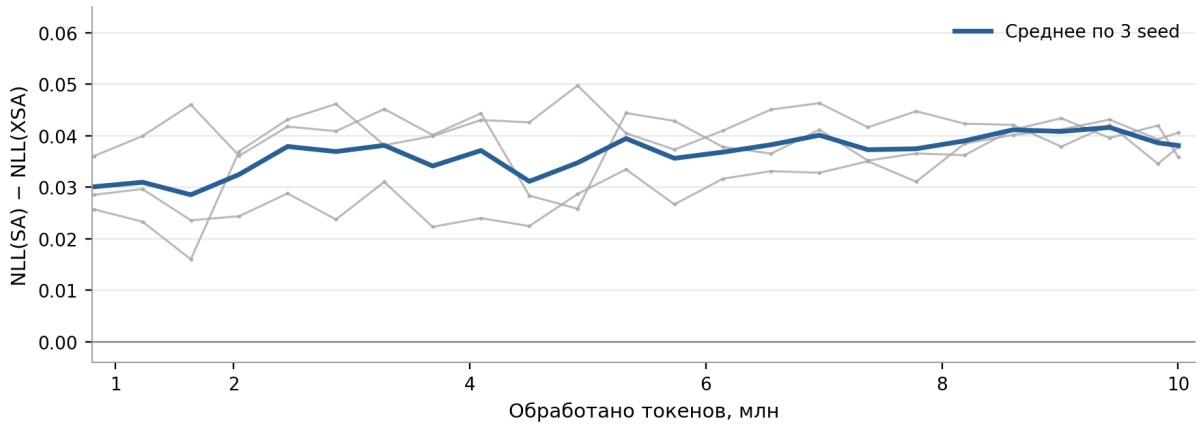


Рис. 1. Разница validation NLL (SA − XSA) в трёх парных запусках. Серые линии — отдельные seed, синяя — среднее. Промежуточные точки оценивались на фиксированной подвыборке; числа в таблице рассчитаны по полной валидации.

Три seed позволяют проверить, повторяется ли знак эффекта при разных инициализациях, но их мало для надёжной оценки статистической неопределённости. Приведённое стандартное отклонение — **не доверительный интервал**.

Контексты 256 и 512: 30 млн токенов

Контекст	NLL SA	NLL XSA	PPL SA	PPL XSA	PPL ниже на
256	5,5497	5,5148	257,16	248,35	3,43%
512	5,5791	5,5381	264,82	254,19	4,01%

При обоих контекстах XSA оказалась лучше. На 512 токенах относительная разница несколько больше, чем на 256, но это **по одному seed на длину**. Делать отсюда вывод, что выигрыш закономерно растёт с контекстом, пока нельзя.

Более длинное обучение: 100 млн токенов

В отдельной паре с контекстом 1024, seed 42 и бюджетом 100 млн токенов NLL уменьшилась с **4,6686** у SA до **4,5589** у XSA. Perplexity составила **106,55** и **95,48** соответственно — снижение на **10,39%**.

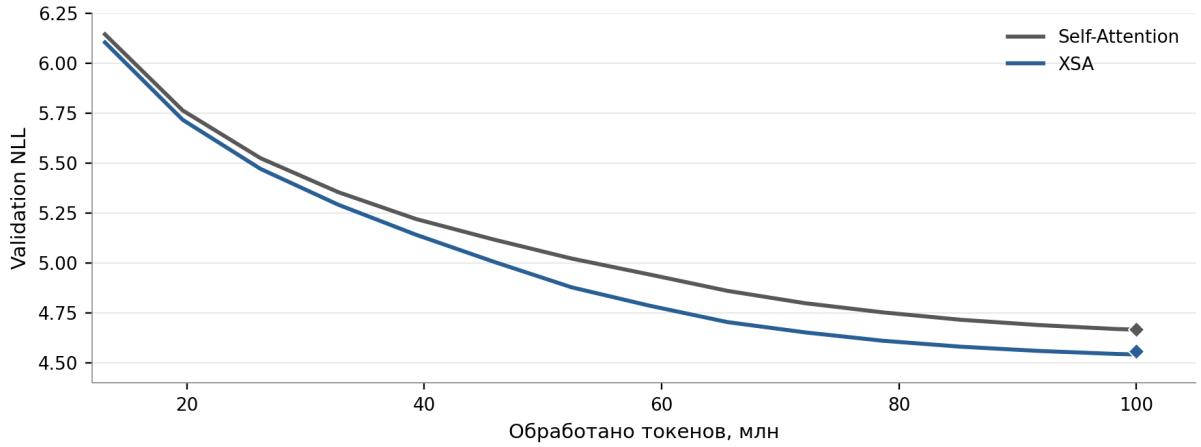


Рис. 2. Validation NLL в серии 100M, контекст 1024. Линии — промежуточная оценка на одной фиксированной подвыборке; ромбы в конце — итоговая оценка по полной валидации. В этой серии использован один seed.

На длинной серии преимущество XSA видно не только по финальной метрике: после нескольких десятков миллионов токенов её validation NLL заметно ниже. Однако серия выполнена **один раз**, а условия обучения отличаются от серии 10M. Поэтому большой выигрыш на 100M нельзя объяснить только увеличением бюджета или длины контекста.

Что ещё показали проверки

Численная диагностика после проекции дала косинусное сходство между выходом XSA и собственным value, близкое к нулю: максимальное по слоям среднее абсолютное значение в сохранённых запусках не превышало примерно $\mathbf{1{,}5 \times 10^{-4}}$. Это ожидаемое следствие формулы и полезная проверка того, что она реализована правильно. Само по себе такое значение ничего не говорит о качестве модели — для этого нужны NLL и PPL.

У проекции есть вычислительная цена. На использованном **Apple M5 (PyTorch/MPS, FP32)** XSA обрабатывала примерно на **3–6% меньше токенов в секунду**, чем SA в соответствующих парах. Это наблюдение относится к нашей реализации и оборудованию, а не к возможному ускорению или замедлению XSA на других GPU.

Вывод и ограничения

В пределах проведённых экспериментов гипотеза статьи подтвердилась: XSA дала меньшую validation NLL во всех шести парах. Самая убедительная часть воспроизведения — серия 10M, где результат повторился на трёх seed. Эксперименты 30M и 100M дополняют картину, но пока служат скорее проверкой того, что эффект не исчезает при других настройках.

Главное ограничение — масштаб. Наша модель значительно меньше моделей из исходной статьи, а бюджет обучения на порядки ниже. Кроме того, серия 30M и длинный запуск 100M проверены лишь на одном seed. Разницу между сериями нельзя приписать только числу обучающих токенов: менялись также длина контекста, размер батча и объём корпуса. Наконец, качество мы оценивали на отложенной части FineWeb, без независимого тестового датасета.

Таким образом, корректный вывод не в том, что XSA всегда лучше обычного Self-Attention, а в более узком утверждении: на нашем GPT-45M и выбранной части FineWeb XSA улучшила качество в прямом сравнении при равных условиях внутри каждой пары. Для дальнейшей проверки прежде всего стоило бы повторить 100M на нескольких seed и провести контекстную серию при одинаковом токенном бюджете.

Литература

1. *Exclusive Self Attention*. arXiv:2603.09078 (2026). https://arxiv.org/abs/2603.09078
2. *FineWeb*, Hugging Face Datasets. https://huggingface.co/datasets/HuggingFaceFW/fineweb