Exclusive Self Attention

Обучение NanoGPT с нуля на FineWeb

Standard Self-Attention vs XSA

Сеничев Сергей, 367532

Зачем менять Self-Attention?

НАБЛЮДЕНИЕ АВТОРОВ

Выход attention часто направлен вдоль собственного value-вектора токена

Attention может повторно передавать информацию, доступную через residual connection

ГИПОТЕЗА

Убрать из attention output компоненту вдоль собственного value

Оставить контекстную составляющую для attention; локальную обработку - residual / FFN

Метод XSA: проекция после attention

СТАНДАРТНЫЙ ATTENTION

$$Y = \mathrm{SDPA}(Q, K, V)$$

EXCLUSIVE SELF-ATTENTION

$$\hat{v}_i = v_i / \max(\|v_i\|, \varepsilon)$$

$$z_i = y_i - \langle y_i, \hat{v}_i \rangle \hat{v}_i$$

ЧТО ОСТАЁТСЯ БЕЗ ИЗМЕНЕНИЙ

causal mask и softmax

RoPE на Q/K (V не вращается)

residual, FFN и выходной W_o

число обучаемых параметров

Важно: для каждой головы отдельно, до W_o

Что показано в оригинальной статье

Авторы обучали модели существенно большего масштаба на FineWeb-100BT

Размер модели	Avg downstream SA	Avg downstream XSA	Δ, п.п.
0,7B	53,22	53,48	+0,26
1,3B	56,16	57,19	+1,03
2,7B	58,06	59,42	+1,36

В статье: около 100 млрд обучающих токенов, стандартный T=2048

Дизайн эксперимента

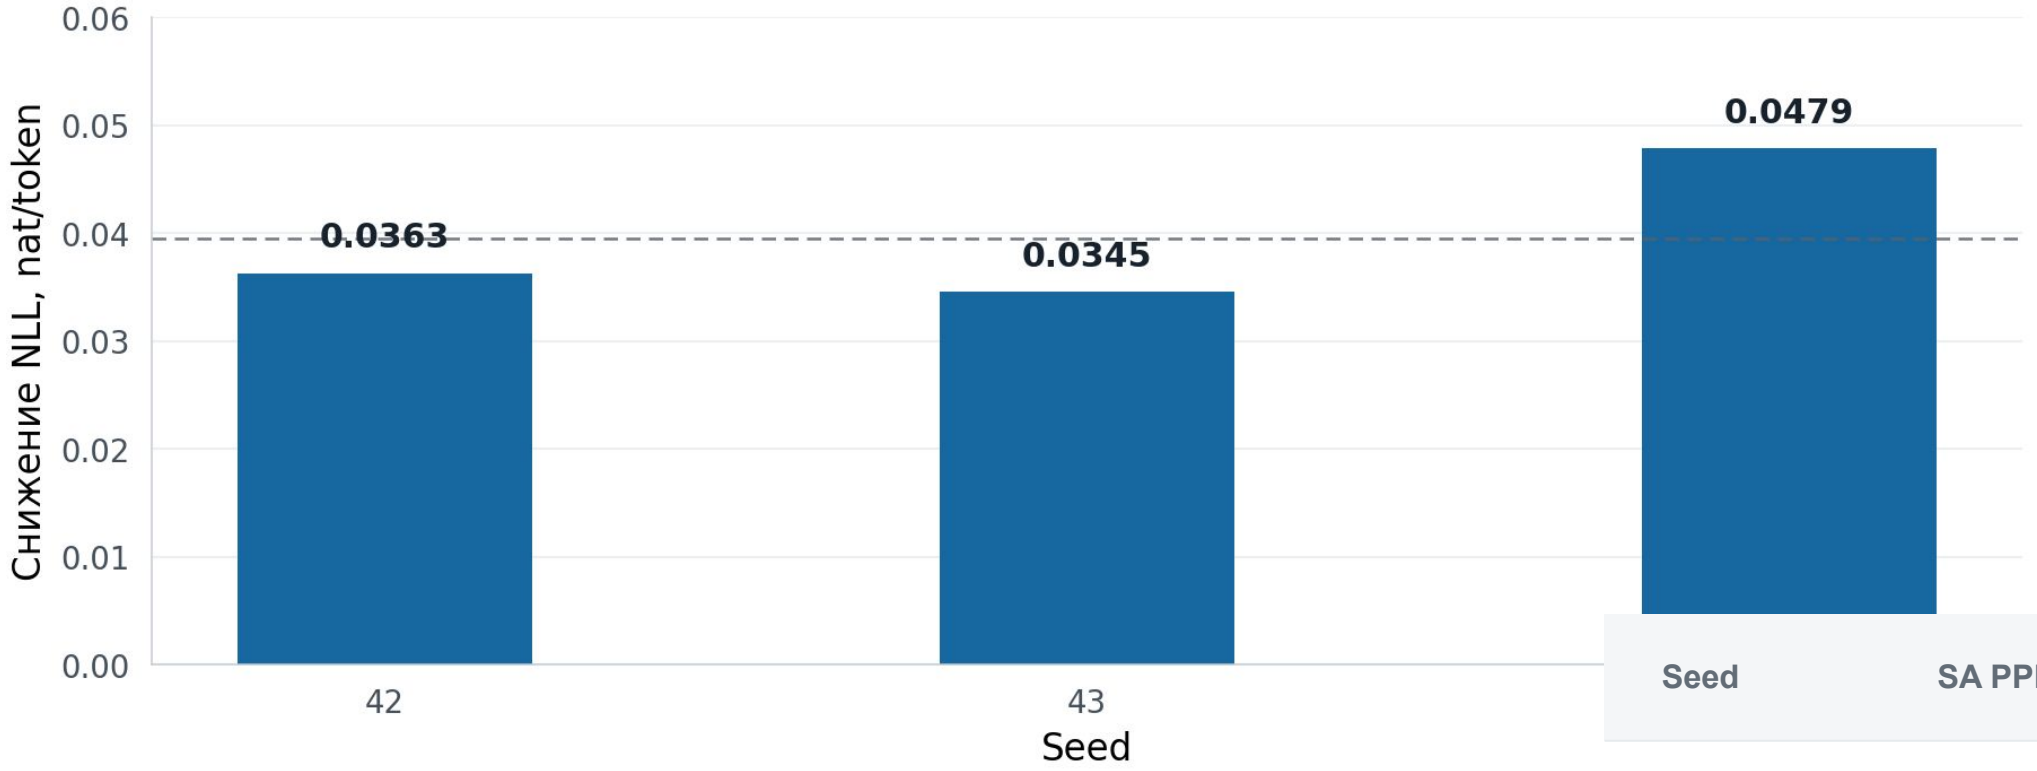
Модель: 6 слоёв, d=512, 8 голов, RoPE; 44 647 936 параметров (SA = XSA)

FineWeb sample-10BT / GPT-2 BPE / AdamW / Apple M5 / MPS FP32

Серия	Длина контекста	Seed	Пары	Val. токенов
10M	256	42 / 43 / 44	3	199 936
30M	256, 512	42	2	≈2 млн
100M	1024	42	1	≈2 млн

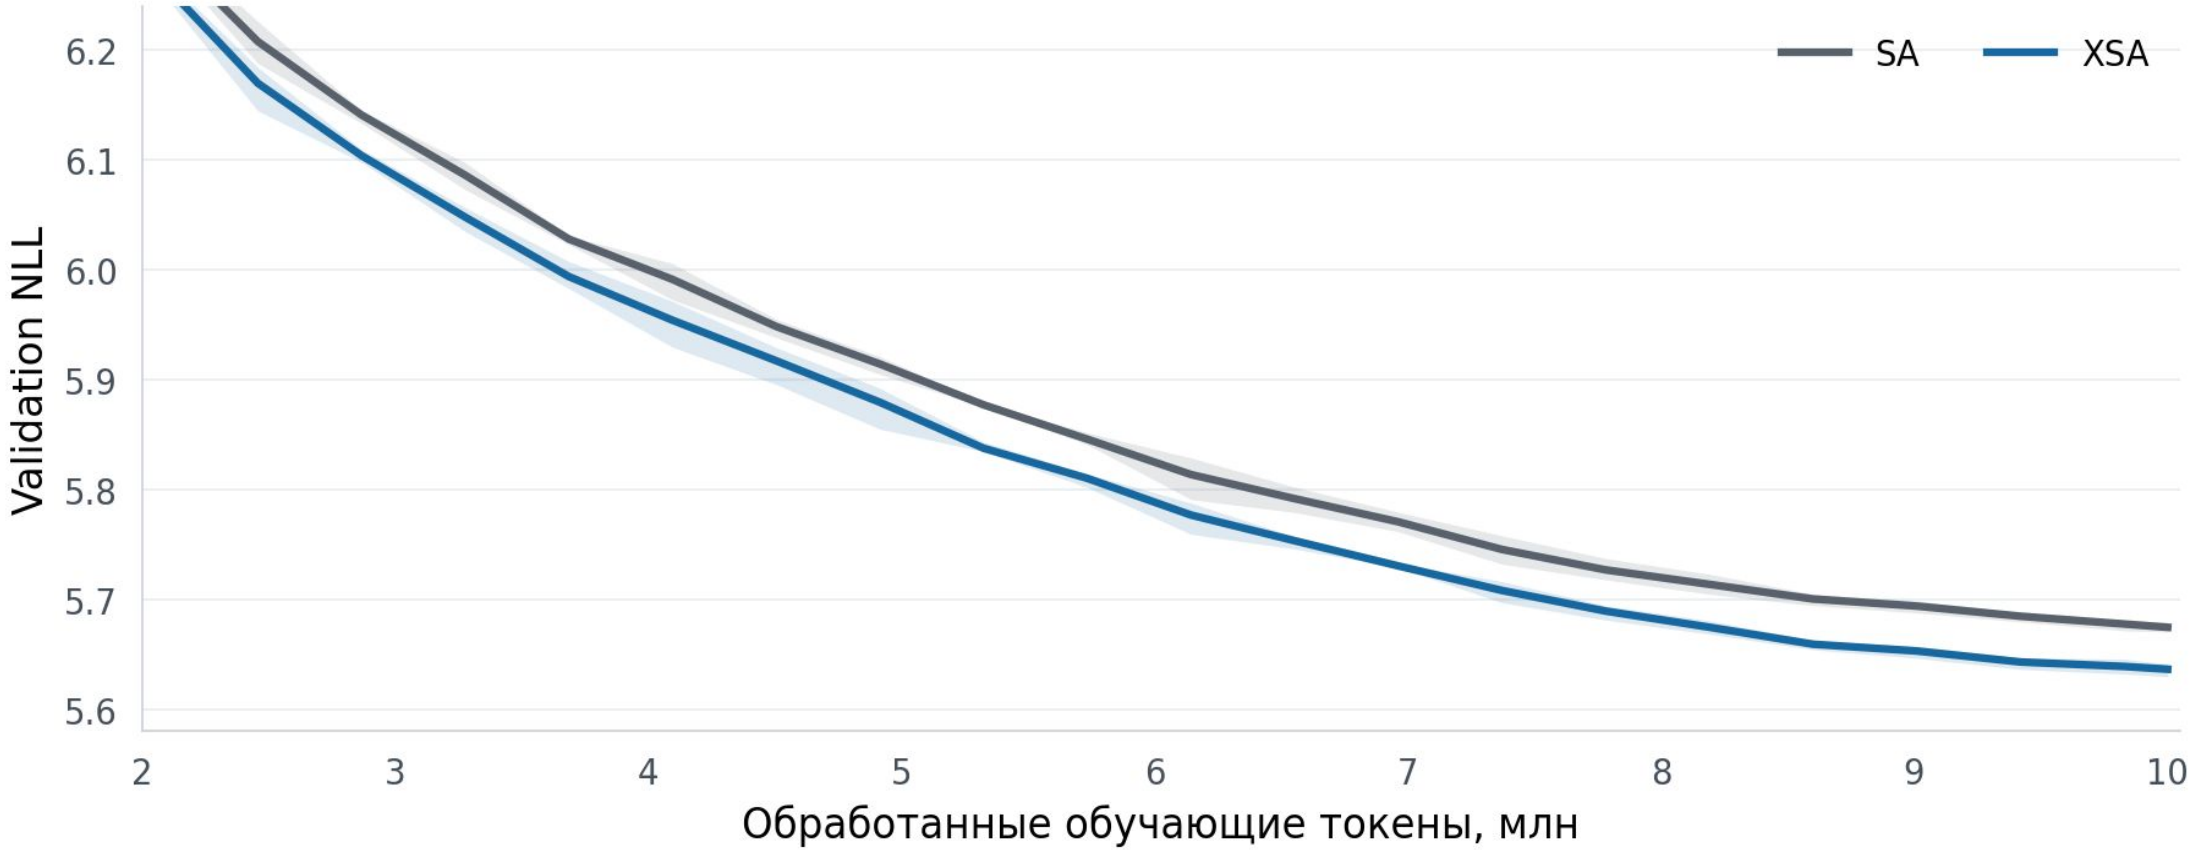
Итого: 6 пар SA/XSA = 12 обучений

10M: XSA лучше на всех трёх seed



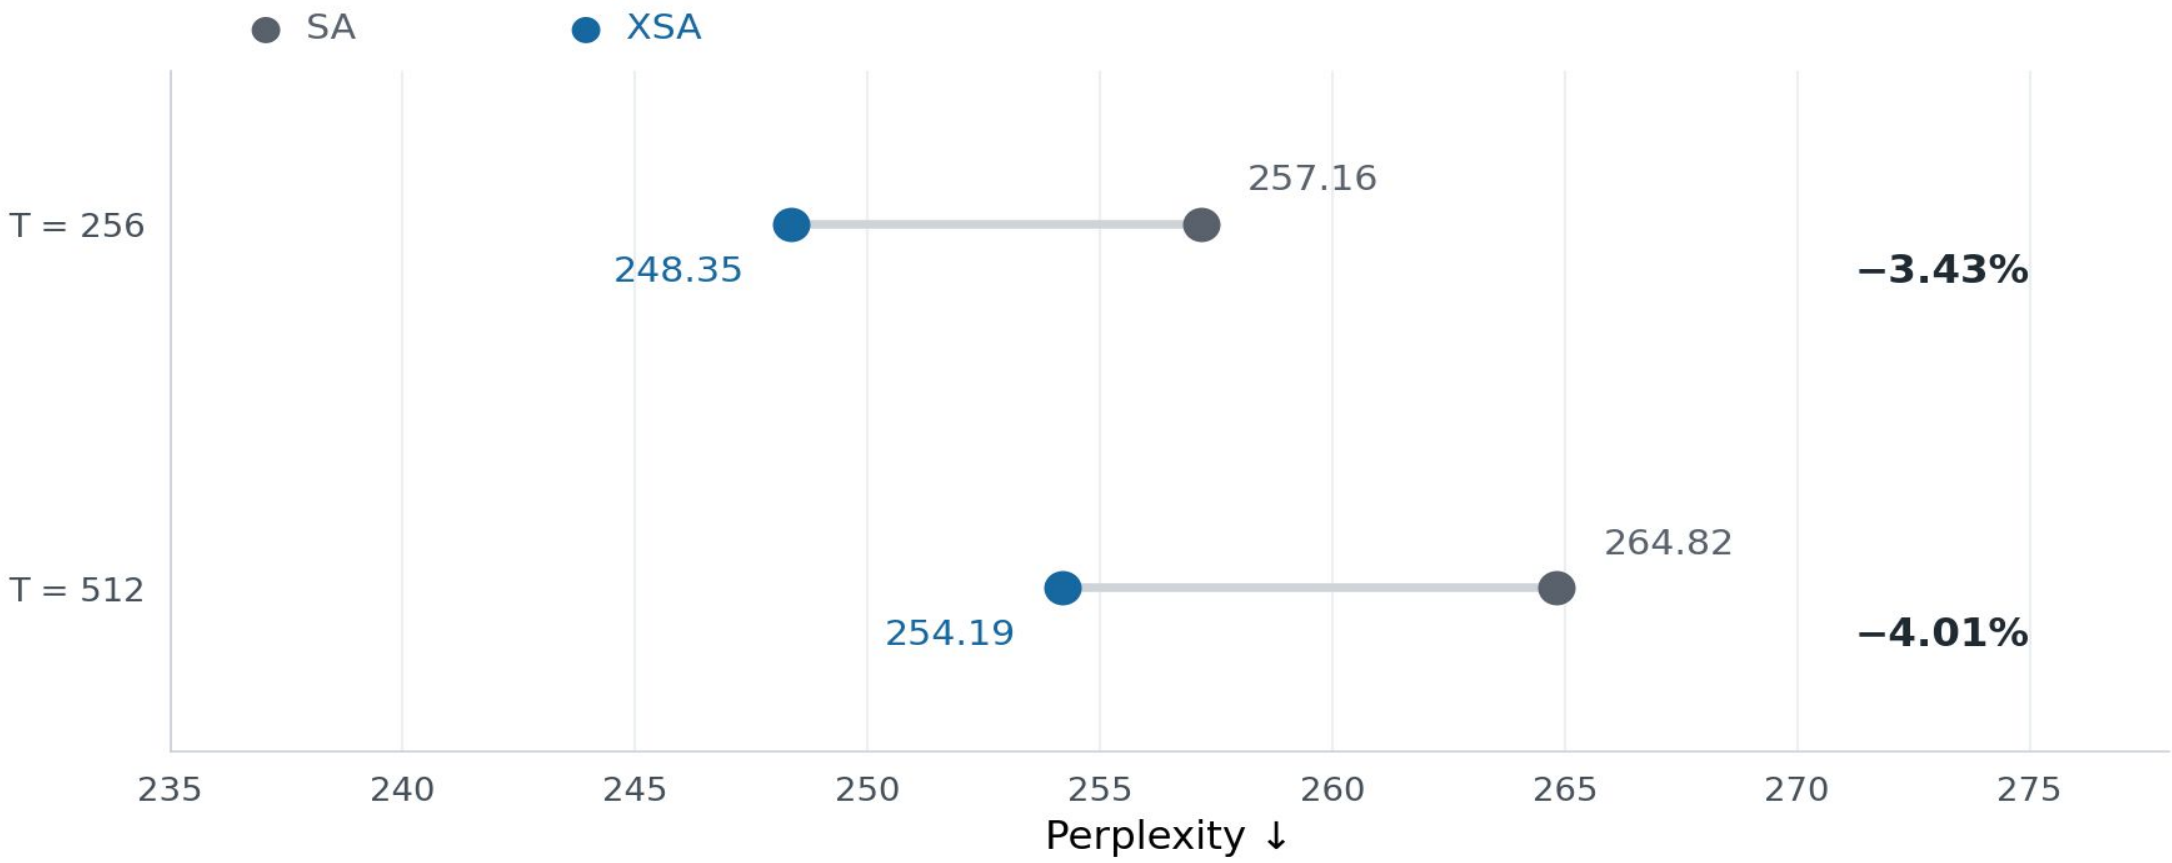
Seed	SA PPL	XSA PPL
42	284,60	274,47
43	285,20	275,52
44	288,17	274,70

10M: преимущество видно по ходу обучения

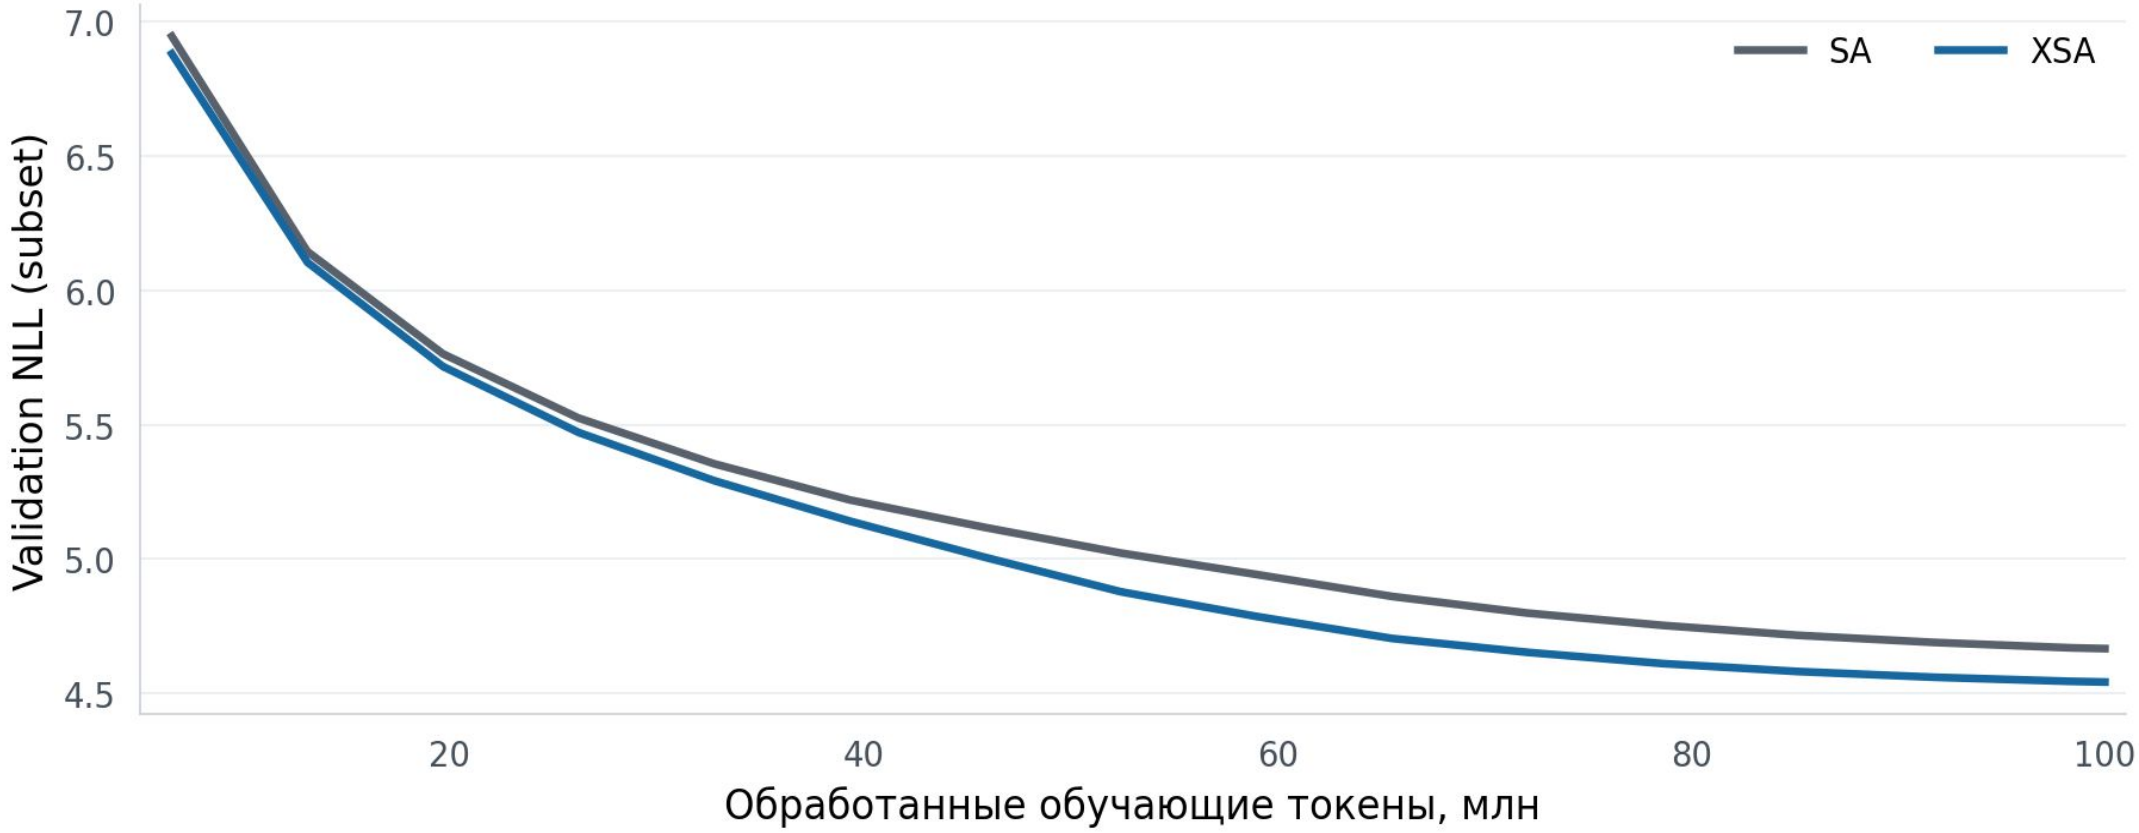


Итоговая средняя PPL: SA 285,99 → XSA 274,90 (−3,88%)

30M: контексты 256 и 512



100M: одна длинная пара при T=1024



106,55

SA · perplexity

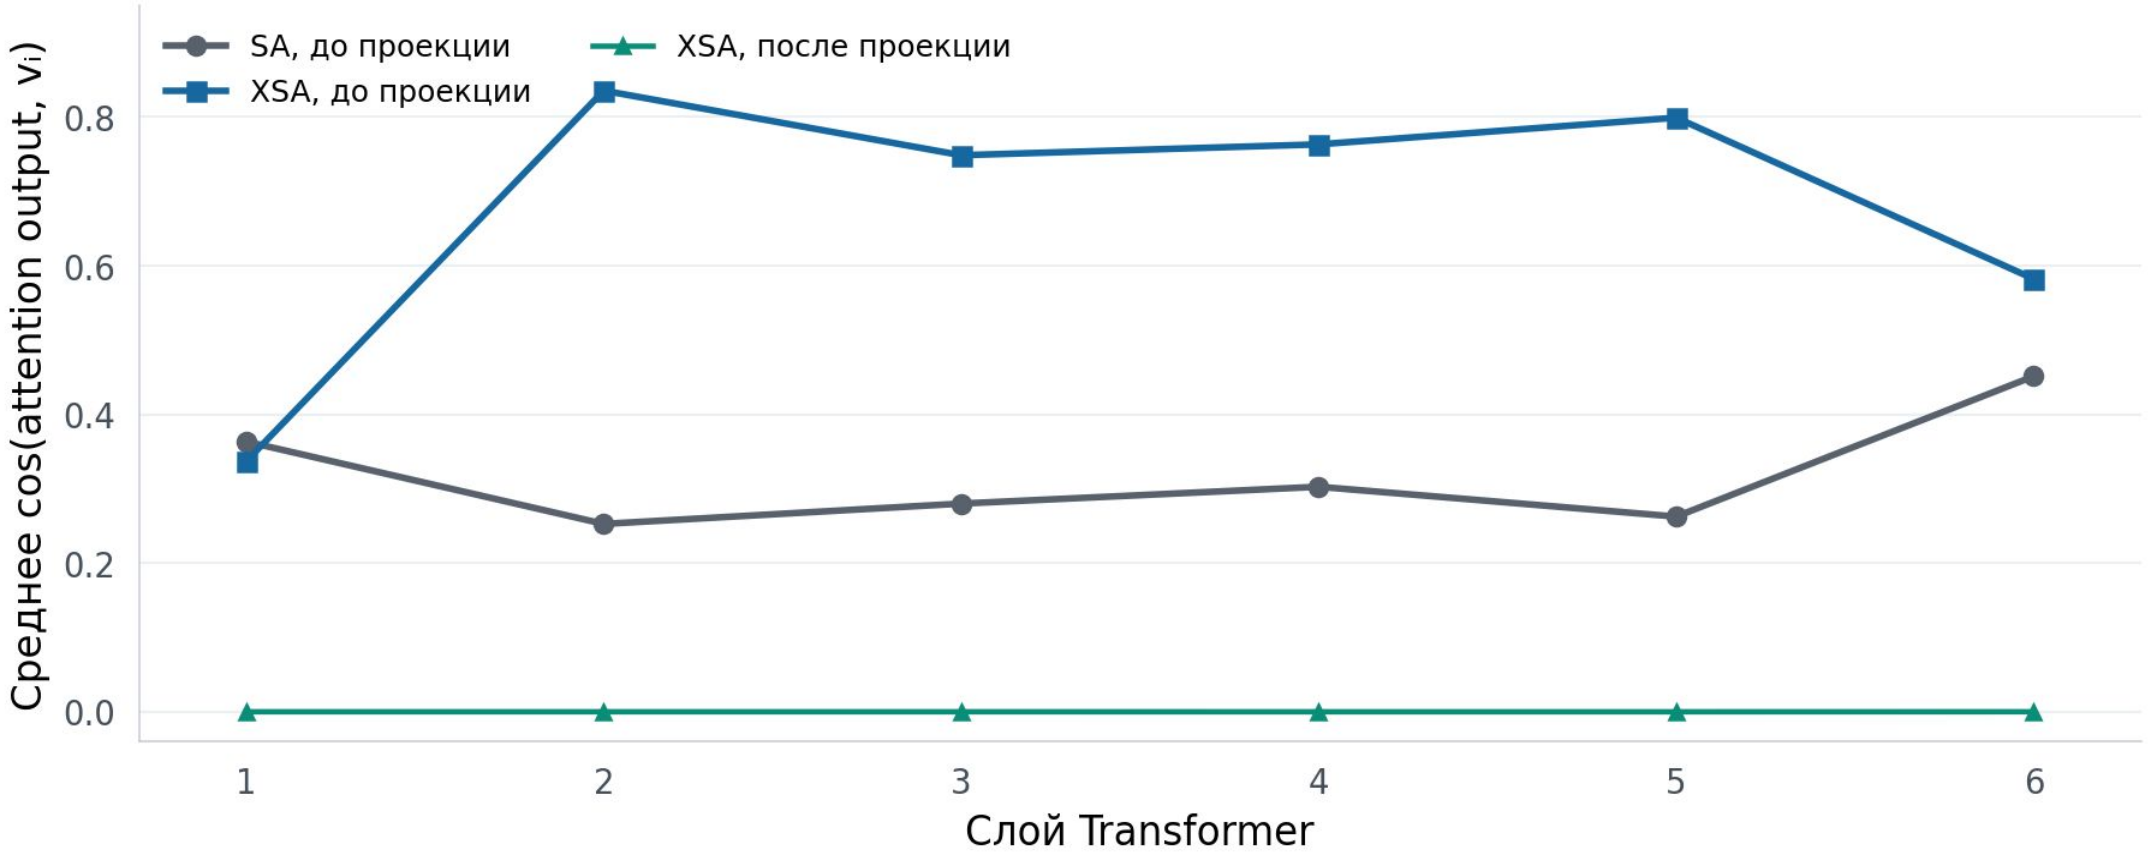
95,48

XSA · perplexity

Итого: −10,39%

Кривые: промежуточная subset-validation; числа справа: full-validation. Одна seed; другой corpus/batch, чем 10M

Диагностика: проекция работает



Вычислительная цена XSA на Apple M5

XSA чуть медленнее, но даёт меньшую perplexity

Серия	SA, tok/s	XSA, tok/s	Изменение
10M · T256, среднее 3 seed	5 093	4 862	−4,54%
30M · T256	5 286	5 026	−4,92%
30M · T512	5 632	5 484	−2,63%
100M · T1024	5 494	5 190	−5,53%

Снижение throughput: от 2,6% до 5,5% в измеренных парах

Воспроизводимость и проверки

ЧТО ЗАФИКСИРОВАНО

hash исходного кода и конфига

seed, начальные веса, sampler windows

revision FineWeb и split по документам

full-val по непересекающимся окнам

Что можно и нельзя заключить

ПОДТВЕРЖДЕНО НА ЭТИХ ДАННЫХ

6 из 6 пар: XSA ниже по full-val NLL / PPL

10M: направление эффекта сохраняется на 3 seed-а

математика XSA корректна по cosine проверкам

НЕ ДОКАЗАНО

Универсальный выигрыш XSA для любых LLM

Рост эффекта с размером контекста / бюджетом

Статистическая устойчивость 30M и 100M (n=1)

Обобщение на отдельный независимый test set

Итог

В условиях нашего эксперимента XSA улучшает качество небольшого GPT.

Серия	Seed	Снижение PPL
10M, T=256	3	3,88% (среднее)
30M, T=256	1	3,43%
30M, T=512	1	4,02%
100M, T=1024	1	10,39%

Следующий шаг: повторы 30M / 100M на одинаковом корпусе и независимый test set.